Universidad San Carlos de Guatemala

Facultad de ingeniería.

Ingeniería en ciencias y sistemas

Proyecto 2:

Procesamiento y Análisis Exploratorio de Datos Masivos en BigQuery

PONDERACIÓN: 25 pts

Tiempo estimado: 22 hrs

Índice

1. MARCO FORMATIVO **3**
1.1. Valor 3
1.2. Competencia(s) 3
1.3. Objetivo SMART 4
2. Resumen Ejecutivo **5**
3. Enunciado del Proyecto **5**
3.1 Descripción del problema a resolver 5
3.2 Alcance del proyecto 5
3.3 Requerimientos técnicos 6
3.4 Entregables 6
4. Material de apoyo 6
5. Metodología **7**
6. Recursos y herramientas a utilizar **7**
7. Desarrollo de Habilidades Blandas **8**
8. Cronograma **8**
9. Rúbrica de Calificación **9**
9.1 Requisitos para optar a la calificación 9
9.2 Resumen de Puntuaciones **10**
9.3 Comentarios Generales 10
9.4 Detalle de la Calificación 11

1. MARCO FORMATIVO

1.1. Valor

Nombre del valor	¿Cómo se aplica en tu laboratorio?
Rigor analítico y responsabilidad profesional	Uso correcto del dataset público, ejecución eficiente de consultas SQL, optimización responsable de recursos en la nube y documentación transparente de hallazgos.

1.2. Competencia(s)

Tipo de Competencia	General y específicas
Competencia General	Maneja e interpreta adecuadamente datos masivos, sean estos estructurados o no estructurados, facilitando su visualización e interpretación de forma eficaz en apoyo a la toma de decisiones.
Competencia Específica	Administra proyectos de análisis de datos en la nube con herramientas como BigQuery y Google Cloud Platform aplicando principios de gobierno de datos, seguridad y control de acceso.

1.3. Objetivo SMART

SMART	Definición	Objetivo redactado
Específico (¿Qué?)	El objetivo es concreto y tangible.	Diseñar e implementar un proceso de análisis exploratorio sobre el dataset público NYC Taxi Trips 2022 en BigQuery, aplicando consultas SQL, tablas derivadas, particiones y clustering para identificar patrones relevantes.
Medible (¿Cuánto?)	El objetivo tiene una medida objetiva de éxito.	Se considerará cumplido al entregar consultas SQL funcionales, evidencia de optimización en bytes procesados, un informe visual con 3 visualizaciones y un README técnico con hallazgos documentados.
Alcanzable (¿Cómo?)	El objetivo debe ser posible con los recursos disponibles.	El objetivo puede lograrse con una cuenta activa de Google Cloud Platform, BigQuery, Google Sheets o Looker Studio y un repositorio organizado en GitHub.
Realista (¿Para qué?)	El objetivo contribuye a metas más amplias.	Fortalece las competencias en análisis de datos masivos, optimización de consultas, documentación técnica y comunicación de hallazgos en entornos de analítica en la nube.
A Tiempo (¿Cuándo?)	El objetivo tiene fecha límite o mejor aún un cronograma de hitos de progreso	Debe entregarse según el cronograma oficial del proyecto: asignación el 08 de abril, entrega el 29 de abril.

2. Resumen Ejecutivo

En esta fase, los estudiantes trabajarán con el dataset público New York City Taxi Trips 2022, disponible en Google BigQuery, que contiene más de 100 millones de registros de viajes de taxi en la ciudad de Nueva York.

El proyecto busca desarrollar competencias en análisis exploratorio de datos masivos utilizando SQL en BigQuery, aplicando técnicas de transformación y optimización de consultas mediante particiones y clustering, y comunicando hallazgos relevantes mediante visualizaciones iniciales.

Utilizando BigQuery ML, se entrenarán al menos 2 modelos distintos de regresión o clasificación, se evaluará su desempeño mediante métricas como precisión, error cuadrático medio o matriz de confusión, y se aplicará sobre nuevos datos. Finalmente, se construirá un tablero en Google Data Studio para comunicar visualmente los resultados y sus implicaciones.

3. Enunciado del Proyecto

3.1 Descripción del problema a resolver

El análisis de grandes volúmenes de datos representa un reto cuando las consultas son lentas, costosas o difíciles de interpretar. En este proyecto se utilizará el dataset público NYC Taxi Trips 2022 en BigQuery, con más de 100 millones de registros, para transformar datos masivos en información útil.

El estudiante deberá diseñar consultas SQL, aplicar técnicas de optimización mediante particiones y clustering, identificar patrones significativos de viaje, costo y comportamiento de usuarios, y presentar hallazgos mediante visualizaciones exploratorias claras.

3.2 Alcance del proyecto

Obligatorio:

- Conectarse al dataset público bigquery-public-data.new_york_taxi_trips.tlc_yellow_trips_2022.
- Realizar consultas SQL avanzadas para calcular métricas descriptivas, analizar distribuciones categóricas y detectar patrones temporales.
- Crear tablas derivadas en su propio proyecto para trabajar subconjuntos optimizados del dataset.
- Implementar particiones por fecha y clustering por ubicaciones para reducir el costo de procesamiento.
- Comparar el rendimiento de las consultas antes y después de aplicar optimización.
- Exportar o enlazar resultados a Google Sheets o Looker Studio para generar al menos 3 visualizaciones exploratorias.

- Documentar el proceso en un repositorio organizado, incluyendo scripts SQL, capturas de consultas, evidencias e informe visual.
- Usar BigQuery ML para entrenar al menos 2 modelo predictivo sobre un dataset limpio.
- Implementación y comparación entre modelos con distintas métricas de evaluación e hiperparametros (como ROC-AUC, RMSE, matriz de confusión o iteraciones)
- Manejo de data leakage por data_split_eval_fraction y split personalizado.
- Ejecutar predicciones sobre nuevos registros.
- Representar resultados y hallazgos de los modelos mediante visualizaciones en el dashboard.

3.3 Requerimientos técnicos

- **Herramientas: Google Cloud Platform (GCP), Google BigQuery, Google Sheets o Looker Studio y GitHub.**
- **Dataset: bigquery-public-data.new_york_taxi_trips.tlc_yellow_trips_2022.**
- **Consultas: uso de funciones agregadas, funciones temporales, filtros, agrupaciones y transformaciones SQL.**
- **Optimización: implementación de particiones (definido por el estudiante) y clustering (definido por el estudiante).**
- **Conocimientos aplicados: análisis exploratorio de datos masivos, optimización de consultas y comunicación visual de hallazgos.**

3.4 Entregables

Tipo	Descripción
Scripts SQL	Archivo(s) .sql con las consultas realizadas en BigQuery para exploración, transformaciones y optimización. Deben estar comentados para explicar la finalidad de cada bloque.
Scripts Big Query ML	Script SQL del modelo entrenado y evaluado y tablas de resultados con predicciones.
Evidencias	Capturas de pantalla de consultas relevantes en BigQuery, conteo de registros, aplicación de particiones/clustering y evidencia de reducción de bytes procesados.

Informe visual	Enlace a un tablero de Looker Studio o archivo de Google Sheets enlazado a BigQuery, con al menos 3 visualizaciones exploratorias de hallazgos clave y la comparación de al menos 2 predicciones con los modelos de ML (Rolling Forecast)
Archivo README	Documento técnico con nombre del proyecto, dataset utilizado, transformaciones realizadas, técnicas de optimización aplicadas, comparación de desempeño (optimizado vs estándar), hallazgos relevantes, explicación de los modelos de regresión o clasificación en BigQuery ML, enlace al informe visual.
Repositorio del curso	Carpeta Proyecto_2 dentro del repositorio SS22S2026_#GRUPO, que contenga todos los archivos del proyecto, documentación y scripts organizados conforme a los lineamientos del laboratorio. En el README deben indicarse ambos integrantes de la pareja.

4. Material de apoyo

- Documentación oficial de BigQuery https://cloud.google.com/bigquery/docs
- Documentación de BigQuery Public Datasets https://cloud.google.com/bigquery/public-data
- Guías de particiones, clustering y Looker Studio https://cloud.google.com/bigquery/docs/partitioned-tables

5. Metodología

1. Conexión y exploración inicial del dataset:
Acceder al dataset público en BigQuery, validar registros y comprender la estructura de las tablas y variables disponibles.

2. Desarrollo de consultas SQL y transformaciones:
Construir consultas para filtrar, agrupar, calcular métricas y preparar datos útiles para el análisis exploratorio.

3. Optimización del procesamiento:
Crear tablas derivadas, aplicar particiones y clustering, y comparar costos de procesamiento antes y después de la optimización.

4. Visualización y análisis de hallazgos:
Generar visualizaciones exploratorias en Google Sheets o Looker Studio para resumir patrones clave del dataset.

5. Documentación final:
Elaborar un repositorio organizado con scripts SQL, evidencias, README técnico y conclusiones relevantes del análisis.

6. Recursos y herramientas a utilizar

Software:

- Google Cloud Platform y Google BigQuery
- Google Sheets o Looker Studio

Plataformas:

- GitHub (para repositorio del proyecto)
- Google Cloud Console (para ejecución y monitoreo de consultas)

Lecturas recomendadas:

- Documentación oficial de BigQuery y datasets públicos.
- Guías de particiones, clustering y optimización de consultas.
- Material de apoyo para visualización de resultados en Google Sheets o Looker Studio.

7. Desarrollo de Habilidades Blandas

En este proyecto se promueven competencias transversales orientadas al análisis responsable, eficiente y comunicable de datos masivos:

- **Pensamiento analítico: interpretación crítica de patrones, tendencias y métricas obtenidas a partir de consultas SQL sobre grandes volúmenes de datos.**
- **Responsabilidad en el uso de recursos cloud: optimización consciente de consultas para reducir costos de procesamiento y uso eficiente de la plataforma.**
- **Comunicación técnica: documentación clara de procedimientos, hallazgos y decisiones de diseño para facilitar la trazabilidad del trabajo.**

8. Cronograma

Tipo	Fecha Inicio	Fecha Fin
Asignación de Proyecto	Semana 12	Semana 12
Elaboración	Semana 12	Semana 14
Calificación	Semana 14	Semana 14

9. Rúbrica de Calificación

9.1 Requisitos para optar a la calificación

Tema	Descripción	Cumple (Sí/No)
Cumplimiento del dataset y plataforma	El proyecto debe desarrollarse en Google BigQuery utilizando el dataset público NYC Taxi Trips 2022, con al menos 1 millón de registros.	
Uso de técnicas requeridas	Aplicación y evidencia de optimización y clustering obligatorio.	
Gestión y entregas del proyecto	El repositorio del curso debe incluir la carpeta Proyecto_2 con scripts SQL, evidencias, README e informe visual organizados correctamente.	
Documentación obligatoria	Debe contener descripción del dataset, transformaciones, optimización aplicada, hallazgos relevantes y enlace al informe visual.	
Evidencias y funcionalidad mínima	Análisis exploratorio y documentación.	

9.2 Resumen de Puntuaciones

Área	Puntos Totales	Puntos Obtenidos
1. Habilidades		
Conexión y comprensión del dataset público	8	
Consultas SQL avanzadas y transformaciones	8	
Optimización con particiones y clustering	12	
Implementación correcta de al menos 2 modelos en BigQuery ML	8	
Evaluación y comparación entre modelos con métricas e hiperparámetros	12	
Prevención de data leakage y manejo correcto del split de datos	12	
Sub-Total Habilidades	**60**	
2. Conocimientos		
Análisis correcto de patrones y tendencias	10	
Visualización de resultados exploratorios y predicciones	10	
Ingeniería de características y justificación de variables	10	
Identificación correcta de variables de entrada, salida y objetivo del modelo	5	
Comparación entre consultas estándar y optimizadas	5	

Área	Puntos Totales	Puntos Obtenidos
Sub-Total Conocimientos	**40**	
TOTAL GENERAL	**100**	

9.3 Comentarios Generales

_____
_

_____
_

_____
_

9.4 Detalle de la Calificación

No.	Criterio de evaluación	Punteo máximo	Satisfactorio (100 % – 61 %)	Necesita mejorar (60 % – 0 %)	Punteo obtenido
1	**Habilidades**	**60**			
1.1	Conexión y comprensión del dataset público	8	Utiliza correctamente el dataset público, valida el volumen de registros y demuestra comprensión de la estructura y calidad de los datos.	Presenta errores en el uso del dataset, validación insuficiente o desconocimiento de la estructura de los datos.	
	Rango del punteo:		8 - 5	4 - 0	
1.2	Consultas SQL avanzadas y transformaciones	8	Aplica consultas SQL funcionales con filtros, funciones agregadas, cálculos y transformaciones coherentes para preparar y explorar los datos.	Las consultas presentan errores, resultados inconsistentes o transformaciones insuficientes para sustentar el análisis.	
	Rango del punteo:		8 - 5	4 - 0	
1.3	Optimización con particiones y clustering	12	Implementa tablas derivadas con particiones y clustering y demuestra con evidencia una mejora en costo o rendimiento de las consultas.	No aplica correctamente la optimización, la evidencia es insuficiente o no demuestra mejora respecto a una consulta estándar.	
	Rango del punteo:		12 - 8	7 - 0	

No.	Criterio de evaluación	Punteo máximo	Satisfactorio (100 % – 61 %)	Necesita mejorar (60 % – 0 %)	Punteo obtenido
1.4	Implementación correcta de al menos 2 modelos en BigQuery ML	8	Entrena correctamente al menos 2 modelos en BigQuery ML, con sintaxis válida, datos preparados y resultados reproducibles.	Los modelos no entrenan correctamente, presentan errores de implementación o no se evidencia el uso adecuado de BigQuery ML.	
	Rango del punteo:		8 - 5	4 - 0	
1.5	Evaluación y comparación entre modelos con métricas e hiperparámetros	12	Compara modelos usando métricas pertinentes e hiperparámetros claramente definidos, interpreta los resultados y justifica la selección final.	La comparación es superficial o incorrecta, faltan métricas relevantes, no hay ajuste de hiperparámetros o no se justifica la elección del modelo.	
	Rango del punteo:		12 - 8	7 - 0	
1.6	Prevención de data leakage y manejo correcto del split de datos	12	Aplica correctamente estrategias para evitar data leakage, define adecuadamente training y evaluation set y justifica el método de partición utilizado.	Existe fuga de información, el split de datos es incorrecto o no se justifica la estrategia de separación entre entrenamiento y evaluación.	
	Rango del punteo:		12 - 8	7 - 0	
Sub-total Habilidades		60			
2	Conocimientos	40			

No.	Criterio de evaluación	Punteo máximo	Satisfactorio (100 % – 61 %)	Necesita mejorar (60 % – 0 %)	Punteo obtenido
2.1	Análisis correcto de patrones y tendencias	10	Identifica y explica hallazgos relevantes en variables temporales, categóricas, geográficas o económicas, sustentados por el análisis realizado.	Los hallazgos son superficiales, poco claros o no están sustentados por el análisis realizado.	
	Rango del punteo:		10 - 6	5 - 0	
2.2	Visualización de resultados exploratorios y predicciones	10	Presenta visualizaciones claras, funcionales y bien interpretadas, que comunican tanto hallazgos exploratorios como resultados de predicción.	Las visualizaciones son confusas, incompletas o no aportan valor para interpretar los hallazgos ni los resultados de los modelos.	
	Rango del punteo:		10 - 6	5 - 0	
2.3	Ingeniería de características y justificación de variables	10	Construye variables derivadas relevantes y justifica su uso dentro del problema analítico o predictivo planteado.	Las variables derivadas son escasas, irrelevantes o no existe justificación clara de por qué fueron utilizadas.	
	Rango del punteo:		10 - 6	5 - 0	

No.	Criterio de evaluación	Punteo máximo	Satisfactorio (100 % – 61 %)	Necesita mejorar (60 % – 0 %)	Punteo obtenido
2.4	Identificación correcta de variables de entrada, salida y objetivo del modelo	5	Define correctamente las variables de entrada, la variable objetivo y el propósito analítico o predictivo de cada modelo.	Existe confusión entre variables de entrada y salida, o no se define con claridad el propósito de los modelos.	
	Rango del punteo:		5 - 3	2 - 0	
2.5	Comparación entre consultas estándar y optimizadas	5	Presenta una comparación clara entre consultas estándar y optimizadas, con evidencia de reducción de bytes procesados o mejora en tiempo de ejecución.	La comparación es inexistente, incompleta o no demuestra de forma clara el beneficio de la optimización aplicada.	
	Rango del punteo:		5 - 3	2 - 0	
Sub-total Conocimientos		40			
Total General		100			